

JAD FALAQ

Ingénieur IA Générative & Agents IA – LLM, RAG & Systèmes multi-agents

Permis B | 22 ans | jadfalaq@gmail.com
linkedin.com/in/jadfalaq | github.com/JadFalaq | www.jadfalaq.online

Stage de fin d'études de 6 mois à partir de janvier 2027

PROFIL

Ingénieur IA Générative, élève-ingénieur en dernière année d'Ingénierie de l'IA à l'**ENSIAS**, passé par **Renault Digital** et **AKWA Group**. A conçu et **mis en production un système multi-agents LLM avec RAG** adopté par une équipe QA, du prototype Copilot Studio à l'application full stack, et développé **cvmatch**, un outil agentique LangGraph **déployé en ligne**. Spécialisé en **agents IA**, **RAG hybride** et **fiabilité des sorties LLM**, selon le principe **« le LLM propose, le code vérifie »** et avec l'**humain dans la boucle**.

EXPÉRIENCE PROFESSIONNELLE

Stagiaire Ingénieur IA – Quality Engineering

Renault Digital | Stage | Casablanca, Maroc — Juin 2026 – Sept. 2026

- **Assistant IA multi-agents en production.** L'ingénieur décrit son besoin en texte, PDF ou image, l'assistant pose des questions puis propose un ticket Jira complet (critères d'acceptation, scénarios Gherkin), créé seulement après validation. Agents en parallèle (analyse, conception des tests, intégration Jira), prototype Copilot Studio puis full stack (FastAPI, React/TypeScript, API Microsoft Copilot). Rédaction passée de 10–20 min à 1–2 min par ticket.
- **RAG & Garde-fous.** RAG sur la documentation et les anciens tickets (OCR, découpage par structure, pgvector, MMR) pour rester cohérent avec l'historique, masquage des données sensibles (Presidio, spaCy), seuil de similarité avec repli en cas de panne du modèle, sorties validées par Pydantic et le parseur Cucumber, 85 % des générations acceptées sans modification.
- **Automatisation & Agile.** Quatre workflows Power Automate lancés de ma propre initiative (fichiers de suivi Smoke et TNR, relances automatiques, gestion des doublons), sprints d'une semaine dans une équipe d'une dizaine d'ingénieurs full stack et DevOps.

ML & Data Engineer – Équipe Data de la DSI

AKWA Group | Stage | Casablanca, Maroc — Juin 2025 – Sept. 2025

- **Détection de transactions manquantes.** Pipeline de machine learning de bout en bout (CRISP-DM) sur les écritures comptables d'Afriware, des ERP Odoo et JDE et de fichiers internes (plus de 6 millions de transactions), comparaison de modèles supervisés et non supervisés, Random Forest retenu (98 % d'accuracy, 85 % de F1-score) et intégré au système existant.

COMPÉTENCES TECHNIQUES

- **LLM & Agents.** LangGraph, LangChain, systèmes multi-agents, tool calling, human-in-the-loop, prompt engineering, sorties structurées (JSON, Pydantic), Azure OpenAI, OpenAI, Anthropic, Gemini, Mistral, Ollama
- **RAG.** Embeddings, pgvector, ChromaDB, chunking sémantique et agentique, recherche hybride (BM25), MMR, RRF, reranking, RAG multimodal, OCR (unstructured.io)
- **Machine & Deep Learning.** PyTorch, TensorFlow, scikit-learn, XGBoost, Hugging Face Transformers, fine-tuning, CNN, LSTM, YOLOv8, U-Net, GNN, knowledge distillation
- **Évaluation & Fiabilité.** LLM-as-a-judge, Langfuse, LangSmith, benchmarks de LLM, calibration de seuils, précision, rappel, F1, mAP
- **MLOps & Déploiement.** Docker, GitHub Actions (CI/CD), MLflow, DVC, FastAPI, Azure (Container Apps), pytest, Git, Linux
- **Développement & Automatisation.** Python, SQL, TypeScript, React, Next.js, PostgreSQL, Power Automate, Agile

FORMATION

Diplôme d'Ingénieur d'État – Ingénierie de l'Intelligence Artificielle (2IA)

ENSIAS, Rabat | Sept. 2024 – Juin 2027

- Apprentissage automatique et profond (réseaux de neurones, reinforcement learning), apprentissage statistique et probabiliste
- Big Data et systèmes distribués, ingénierie des données, séries temporelles, traitement multimédia (texte, image)

Classes Préparatoires aux Grandes Écoles (CPGE) – Mathématiques-Physique

CPGE Mohammed V, Casablanca | Sept. 2022 – Juin 2024

PROJETS ACADÉMIQUES

- **cvmatch – Agent LangGraph & RAG hybride (démo en ligne).** Confronte un CV à une offre compétence par compétence, retrouve la preuve par RAG hybride (BM25 + embeddings, fusion RRF), calcule un score en code et propose des reformulations sans rien inventer. « Le LLM propose, le code vérifie », avec citations contrôlées mot pour mot, validation humaine et Docker sur Azure
- **Stratégies RAG.** Pipeline RAG (Azure OpenAI, ChromaDB) comparant chaque étape, du découpage (caractères, sémantique, agentique par LLM) à la recherche (similarité, seuil, MMR, multi-query) et à la fusion RRF, avec RAG multimodal
- **Détection de pathologies dentaires – Computer Vision & MLOps.** YOLOv8 sur 1 808 radiographies (24 891 annotations auditées, 14 classes remappées en 7), évalué sur validation, test et jeu externe, avec pipeline déployé en continu (DVC, MLflow, CI/CD, Azure)
- **NLP & Fine-tuning.** Fine-tuning d'AraBERT pour détecter la désinformation médicale dans des tweets arabes, comparé à une baseline TF-IDF, 87 % d'accuracy et 0,87 de F1 macro

SOFT SKILLS

- **Esprit d'entrepreneuriat.** Automatisations lancées de ma propre initiative, sites e-commerce créés pour des clients
- **Écoute & Responsabilité.** Produit construit à partir des retours des utilisateurs, aucune action de l'IA sans validation humaine

LANGUES

Français (langue maternelle) – Arabe (langue maternelle) – Anglais (bilingue)